



Tecnologia em Banco de Dados

PROJETO APLICADO II

Análise de Sentimentos e Classificação de Avaliações de E-commerce utilizando o Dataset Olist

São Paulo, agosto de 2026

Sumário

1. Grupo de trabalho	3
2. Introdução	3
3. Premissas do Projeto	3
3.1 Definição da Organização	3
3.2 Área de Atuação	3
3.3 Apresentação dos Dados (Metadados)	3
4. Objetivos e Metas	4
4.1 Objetivo Geral	4
4.2 Objetivos Específicos	4
4.3 Metas	5
5. Cronograma de Atividades	5
6. Repositório no GitHub	7
7. Referências	8

Tabelas

Tabela 1 – Apresentação dos dados	4
Tabela 2 – Cronograma do projeto	5
Tabela 3 – Estrutura dos arquivos no repositório	7

1. Grupo de trabalho

Grupo Drop Table

Integrantes:

- Igor Eduardo Dallan do Couto, RA: 10748144
- Jaqueline de Oliveira Alves, RA: 10755023
- Kayo Oliveira Nukui, RA: 10356420
- Lucas de Lima Mendes, RA: 10756562

2. Introdução

Este projeto tem como objetivo analisar o nível de satisfação dos consumidores no comércio eletrônico a partir de avaliações textuais reais extraídas do dataset da Olist. Utilizando técnicas de Processamento de Linguagem Natural (NLP) e algoritmos de Aprendizado de Máquina, o estudo busca mapear sentimentos (positivos, neutros e negativos), identificar os principais motivos de insatisfação dos clientes e construir modelos preditivos para automatizar a classificação de feedbacks. Com isso, visa-se fornecer insights estratégicos para aprimorar a tomada de decisão e a experiência do usuário no ambiente de marketplace.

3. Premissas do Projeto

3.1 Definição da Organização

A ConectaShop é uma empresa fictícia que atua como marketplace de um e-commerce, conectando pequenos e médios lojistas a consumidores em todo o território nacional. A empresa oferece uma ampla variedade de categorias de produtos (moda, eletrônicos, casa e decoração, beleza, entre outras) e tem como diferencial estratégico o acompanhamento contínuo da satisfação do cliente ao longo da jornada de compra.

3.2 Área de Atuação

O comércio eletrônico (e-commerce) com foco em marketplace multicategoria e sendo um modelo de negócio em que há a intermediação de vendas entre lojistas parceiros (sellers) e consumidores finais.

3.3 Apresentação dos Dados (Metadados)

O projeto utilizará dados de texto como avaliações e comentários escritos por clientes após a finalização de seus pedidos. A base escolhida é o Brazilian E-Commerce Public Dataset by Olist, disponível publicamente no Kaggle, que reúne cerca de 100 mil pedidos realizados entre 2016 e 2018 em um marketplace brasileiro real. Para este projeto será utilizado o

arquivo de avaliações (order_reviews), que contém comentários textuais em português e as notas atribuídas pelos clientes, sendo ideal para tarefas de Processamento de Linguagem Natural (NLP), como análise de sentimento, classificação de texto e extração de tópicos.

Fonte: [Kaggle - Brazilian E-Commerce Public Dataset by Olist](https://www.kaggle.com/olist-br/brazilian-e-commerce).

Principais campos (metadados) do arquivo de avaliações utilizado:

Tabela 1 – Apresentação dos dados

Campo	Descrição
review_id	Identificador único da avaliação.
order_id	Identificador único do pedido associado à avaliação.
review_score	Nota atribuída pelo cliente ao pedido, de 1 (péssimo) a 5 (ótimo).
review_comment_title	Título do comentário deixado pelo cliente (texto livre, opcional).
review_comment_message	Corpo do comentário/avaliação em texto livre, principal campo de interesse para o NLP.
review_creation_date	Data em que a pesquisa de satisfação foi enviada ao cliente.
review_answer_timestamp	Data e hora em que o cliente respondeu à avaliação.

A escolha desta base de dados justifica-se por sua capacidade de reproduzir com precisão o contexto operacional do e-commerce, viabilizando a aplicação prática de técnicas de Processamento de Linguagem Natural e Aprendizado de Máquina sobre dados textuais reais. Ao integrar o conteúdo ministrado nos componentes curriculares do semestre com um cenário mercadológico autêntico, a investigação possibilita mensurar a percepção e a experiência do consumidor, fornecendo subsídios informados para subsidiar tomadas de decisão voltadas ao aprimoramento contínuo de produtos e serviços.

4. Objetivos e Metas

4.1 Objetivo Geral

Desenvolver um projeto de ciência de dados que utilize técnicas de Processamento de Linguagem Natural para analisar as avaliações textuais de clientes, identificando padrões de satisfação e insatisfação que possam apoiar decisões de negócio.

4.2 Objetivos Específicos

- Coletar, tratar e preparar os dados textuais das avaliações de clientes (limpeza, remoção de valores nulos, normalização de texto e retirada de duplicatas).
- Realizar análise exploratória dos dados (EDA), incluindo distribuição das notas e frequência de termos.
- Aplicar técnicas de NLP para análise de sentimento dos comentários (positivo, neutro, negativo).
- Construir e avaliar um modelo de aprendizado de máquina para classificação automática do sentimento/nota da avaliação.
- Apresentar os resultados de forma clara, com visualizações e recomendações de negócio.

4.3 Metas

- **Meta 1:** preparar e documentar a base de avaliações até a Etapa 2 e, até a Etapa 3, treinar e avaliar um modelo de classificação que alcance F1-score mínimo de 0,80 para a classe negativa (review_score 1 e 2).
- **Meta 2:** identificar e categorizar pelo menos cinco temas recorrentes de insatisfação, como atraso na entrega, produto danificado e atendimento, por meio de análise de termos e modelagem de tópicos até a Etapa 3.
- **Meta 3:** comparar a classificação do texto com a nota da avaliação, adotando as classes negativa (1 e 2), neutra (3) e positiva (4 e 5), e documentar precisão, recall, F1-score e matriz de confusão até a Etapa 3.

5. Cronograma de Atividades

O cronograma completo e editável pode ser consultado na [planilha Cronograma - V270826.xlsx](#) disponível no repositório público.

Tabela 2 – Cronograma do projeto

TAREFA	ATRIBUÍDO PARA	PROGRESSO	INÍCIO	TÉRMINO
Etapa 1		100%		
Definição do grupo de trabalho	Geral	100%	10/8/26	25/8/26
Buscar dataset	Igor	100%	24/8/26	25/8/26

Detalhamento da organização	Igor/Lucas	100%	25/8/26	27/8/26
Detalhamento da área de atuação	Igor/Kayo	100%	25/8/26	27/8/26
Apresentação (metadados)	Igor/Jaqueline	100%	25/8/26	27/8/26
Criar cronograma do projeto	Jaqueline	100%	25/8/26	26/8/26
Criar diretório no GitHub	Lucas	100%	25/8/26	26/8/26
Entregável Etapa 1	Kayo	100%	28/8/26	28/8/26
Etapa 2				
Definição das bibliotecas	-	0%	29/8/26	2/9/26
Análise exploratória da base	-	0%	1/9/26	7/9/26
Tratamento da base de dados (preparação)	-	0%	7/9/26	18/9/26
Tratamento da base de dados (treinamento)	-	0%	7/9/26	18/9/26
Detalhamento das bases teóricas dos métodos	-	0%	19/9/26	24/9/26
Detalhamento do cálculo de acurácia	-	0%	19/9/26	24/9/26
Entregável Etapa 2	-	0%	25/9/26	25/9/26
Etapa 3				
Consolidação do método analítico	-	0%	26/9/26	10/10/26
Aplicação das medidas de acurácia	-	0%	11/10/26	19/10/26
Descrição dos resultados preliminares	-	0%	17/10/26	22/10/26
Esboço do Storytelling	-	0%	17/10/26	22/10/26
Entregar PDF Etapa 3	-	0%	23/10/26	23/10/26
Etapa 4				
Relatório técnico do projeto	-	0%	24/10/26	7/11/26

Apresentação do Storytelling	-	0%	2/11/26	14/11/26
Edição e publicação do vídeo	-	0%	11/11/26	19/11/26
Revisão do repositório no GitHub	-	0%	18/11/26	19/11/26
Entregável Etapa 4	-	0%	20/11/26	20/11/26

6. Repositório no GitHub

Abaixo está a estrutura do repositório com a descrição de cada pasta e arquivo relevante.

Repositório público do projeto: <https://github.com/lucasmendes94/Drop-Table-Projeto-Aplicado-II>

Tabela 3 – Estrutura dos arquivos no repositório

Pasta / arquivo	Descrição
README.md	Apresentação do projeto, acesso rápido aos documentos, equipe, estrutura e andamento.
[PA2] Etapa 1 - Drop Table - V280826.docx	Relatório técnico da Etapa 1 revisado após os comentários do professor.
Cronograma - V270826.xlsx	Cronograma completo, editável e legível das quatro etapas.
VALIDACAO_COMENTARIOS.md	Matriz de atendimento dos comentários e evidências de cada correção.
docs/rascunhos/	Versões anteriores preservadas para histórico.
data/raw/	Dados originais mantidos localmente e fora do versionamento.
data/processed/	Dados tratados e derivados mantidos localmente.
notebooks/	Aquisição, EDA, preparação textual, modelagem e avaliação.
src/	Funções e pipeline reutilizável do projeto.
reports/figures/	Gráficos e imagens usados nos relatórios e na apresentação.
requirements.txt	Dependências previstas para análise e modelagem em Python.

7. Referências

As fontes abaixo fundamentam a escolha da base de dados e os métodos previstos para classificação de texto e modelagem de tópicos.

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle. Disponível em:

<https://www.kaggle.com/olistbr/brazilian-ecommerce/home>. Acesso em: 27 ago. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, n. 85, p. 2825-2830, 2011. Disponível em:

<https://www.jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 27 ago. 2026.

BLEI, D. M.; NG, A. Y.; JORDAN, M. I. Latent Dirichlet Allocation. Journal of Machine Learning Research, v. 3, p. 993-1022, 2003. Disponível em:

<https://jmlr.org/papers/v3/blei03a.html>. Acesso em: 27 ago. 2026.

JURAFSKY, D.; MARTIN, J. H. Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models. 3. ed. Manuscrito online, 2026. Disponível em:

<https://web.stanford.edu/~jurafsky/slp3/index.html>. Acesso em: 27 ago. 2026.