Tecnologia em Banco de Dados

PROJETO APLICADO II

Análise de Sentimentos e Classificação de Avaliações de E-commerce utilizando o Dataset Olist

São Paulo, outubro de 2026

Sumário

1. Grupo de trabalho 4
2. Introdução 4
3. Premissas do Projeto 4
   3.1 Definição da Organização 4
   3.2 Área de Atuação 4
   3.3 Apresentação dos Dados (Metadados) 4
4. Objetivos e Metas 5
   4.1 Objetivo Geral 5
   4.2 Objetivos Específicos 5
   4.3 Metas 6
5. Linguagem de Programação e Bibliotecas Utilizadas 6
6. Análise Exploratória da Base de Dados 6
7. Tratamento da Base de Dados (Preparação e Treinamento) 7
8. Descrição das bases teóricas dos métodos 7
   8.1 Fundamentação Teórica 7
      8.1.1 Regressão Logística 7
      8.1.2 Linear Support Vector Classifier 8
   8.2 Metodologia e Implementação dos Modelos 8
      8.2.1 Aplicando a Regressão Logística 8
      8.2.2 Aplicando o LinearSVC 9
   8.3 Resultados e Discussão 9
      8.3.1 Desempenho da Regressão Logística 9
      8.3.2 Desempenho do LinearSVC 10
9. Cálculo de Acurácia 10
   9.1 Escolha das métricas 10
   9.2 Distribuição das classes e limites da acurácia 11
   9.3 Matriz de confusão 11
   9.4 Métricas de cada classe 11
   9.5 Resultado frente à Meta 1 12
   9.6 Curvas ROC e precisão-recall 12
   9.7 Validação cruzada 12
   9.8 Textos semelhantes entre treino e teste 13
   9.9 Sensibilidade ao limiar 13
   9.10 Síntese da avaliação 13
10. Avaliação Final 14
11. Cronograma de Atividades 14
12. Repositório no GitHub 16

PARTE III — ETAPA 3: APLICAÇÃO DO MÉTODO ANALÍTICO, AVALIAÇÃO DE DESEMPENHO, PROPOSTA DE PRODUTO E STORYTELLING 18
13. Aplicação do Método Analítico e Otimização de Hiperparâmetros 18
13.1 Otimização do Parâmetro de Regularização C 18
13.2 Decomposição Temática e Regras Léxicas de Insatisfação 19
14. Medidas de Acurácia, Validação por Pedido e Limiares Operacionais 20
14.1 Desempenho no Teste Histórico 20
14.2 Auditoria de Particionamento e Validação Complementar Agrupada por Pedido 20
14.3 Calibração de Probabilidades e Simulação de Limiares 20
15. Resultados Preliminares, Proposta de Produto e Modelo de Negócios 21
15.1 Caracterização da Solução Proposta 21
15.2 Beneficiários Operacionais Propostos 22
15.3 Modelo de Negócios e Estrutura de Precificação Proposta 22
16. Esboço de Storytelling em Quatro Atos 23
17. Síntese de Rastreabilidade e Limitações Metodológicas 24
17.1 Limitações Técnicas Reconhecidas 24
18. Referências 25

Tabelas

Tabela 1 – Apresentação dos dados 5
Tabela 2 – Matriz de confusão da Regressão Logística no conjunto de teste (linhas: classe real; colunas: classe prevista). 11
Tabela 3 – Decomposição um contra todos da matriz de confusão e métricas por classe no conjunto de teste. 11
Tabela 4 – Principais resultados do modelo oficial. 13
Tabela 5 – Cronograma do projeto 15
Tabela 6 – Estrutura dos arquivos no repositório 16
Tabela 7 — Otimização de C em validação cruzada estratificada de 5 partições no treino 18
Tabela 8 — Temas de insatisfação identificados por regras léxicas no conjunto de treino 19
Tabela 9 — Simulação de limiares operacionais na probabilidade calibrada no teste agrupado 21
Tabela 10 — Síntese de rastreabilidade das afirmações numéricas da Etapa 3 24

1. Grupo de trabalho

Grupo Drop Table

Integrantes:

- Igor Eduardo Dallan do Couto, RA: 10748144
- Jaqueline de Oliveira Alves, RA: 10755023
- Kayo Oliveira Nukui, RA: 10356420
- Lucas de Lima Mendes, RA: 10756562

2. Introdução

Este projeto analisa a satisfação de consumidores a partir de avaliações textuais da Olist. O trabalho usa processamento de linguagem natural e aprendizado de máquina para classificar os comentários em positivos, neutros e negativos e investigar motivos de insatisfação. Os resultados servem de base para uma proposta de triagem de feedbacks no contexto de um marketplace.

3. Premissas do Projeto

3.1 Definição da Organização

A ConectaShop é uma empresa fictícia usada como cenário do projeto. No caso proposto, ela intermedeia vendas entre lojistas parceiros e consumidores em diferentes categorias de produtos. O acompanhamento das avaliações de pós-venda é a atividade examinada neste estudo.

3.2 Área de Atuação

A organização fictícia atua no comércio eletrônico como marketplace multicategoria, intermediando vendas de lojistas parceiros para consumidores finais.

3.3 Apresentação dos Dados (Metadados)

O estudo utiliza avaliações e comentários escritos por clientes após seus pedidos. A fonte é o Brazilian E-Commerce Public Dataset by Olist, disponível no Kaggle, com registros de um marketplace brasileiro entre 2016 e 2018. O arquivo de avaliações contém notas e comentários em português, que permitem estudar classificação de texto, sentimento e temas recorrentes.

Fonte: Kaggle - Brazilian E-Commerce Public Dataset by Olist.

Principais campos (metadados) do arquivo de avaliações utilizado:

Tabela 1 – Apresentação dos dados

Campo	Descrição
review_id	Identificador único da avaliação.
order_id	Identificador único do pedido associado à avaliação.
review_score	Nota atribuída pelo cliente ao pedido, de 1 (péssimo) a 5 (ótimo).
review_comment_title	Título do comentário deixado pelo cliente (texto livre, opcional).
review_comment_message	Corpo do comentário/avaliação em texto livre, principal campo de interesse para o NLP.
review_creation_date	Data em que a pesquisa de satisfação foi enviada ao cliente.
review_answer_timestamp	Data e hora em que o cliente respondeu à avaliação.

A base reúne notas e comentários de compras reais, o que permite aplicar as técnicas estudadas a um problema concreto de classificação textual. Os resultados descrevem padrões nas avaliações analisadas; sua utilidade operacional para a ConectaShop ainda depende da implementação e da avaliação da solução proposta.

4. Objetivos e Metas

4.1 Objetivo Geral

Desenvolver um projeto de ciência de dados que utilize técnicas de Processamento de Linguagem Natural para analisar as avaliações textuais de clientes, identificando padrões de satisfação e insatisfação que possam apoiar decisões de negócio.

4.2 Objetivos Específicos

- Coletar, tratar e preparar os dados textuais das avaliações de clientes (limpeza, remoção de valores nulos, normalização de texto e retirada de duplicatas).
- Realizar análise exploratória dos dados (EDA), incluindo distribuição das notas e frequência de termos.
- Aplicar técnicas de NLP para análise de sentimento dos comentários (positivo, neutro, negativo).
- Construir e avaliar um modelo de aprendizado de máquina para classificação automática do sentimento/nota da avaliação.

- Apresentar os resultados de forma clara, com visualizações e recomendações de negócio.

4.3 Metas

- **Meta 1:** preparar e documentar a base de avaliações até a Etapa 2 e, até a Etapa 3, treinar e avaliar um modelo de classificação que alcance F1-score mínimo de 0,80 para a classe negativa (review_score 1 e 2).
- **Meta 2:** identificar e categorizar pelo menos cinco temas recorrentes de insatisfação, como atraso na entrega, produto danificado e atendimento, por meio de análise de termos e modelagem de tópicos até a Etapa 3.
- **Meta 3:** comparar a classificação do texto com a nota da avaliação, adotando as classes negativa (1 e 2), neutra (3) e positiva (4 e 5), e documentar precisão, recall, F1-score e matriz de confusão até a Etapa 3.

5. Linguagem de Programação e Bibliotecas Utilizadas

O que definir neste item

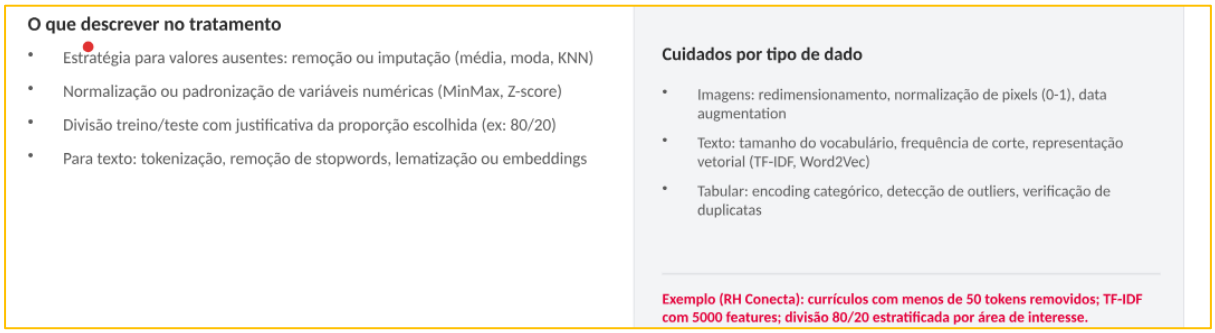
- Python é a linguagem padrão; confirmem que todos têm acesso ao ambiente
- Listem as bibliotecas principais: pandas, scikit-learn, matplotlib e as específicas do tipo de dado
- Informem o repositório GitHub que será usado para o trabalho colaborativo

- Bibliotecas de terceiros
  - Pandas
  - Matplotlib
  - Seaborn
  - Scikit-learn
  - Joblib
- Bibliotecas Nativas
  - Json
  - Re
  - Unicodedata
  - Argparse
  - Pathlib
  - __future__

6. Análise Exploratória da Base de Dados

A EDA mostra que o grupo conhece os dados antes de modelar. Mostre distribuições, nulos, estatísticas descritivas e ao menos um gráfico.

7. Tratamento da Base de Dados (Preparação e Treinamento)



8. Descrição das bases teóricas dos métodos

Esta seção apresenta os métodos usados para classificar os comentários. A Meta 1 exige F1-score de pelo menos 0,80 para a classe negativa, formada pelas notas 1 e 2. Foram comparadas Regressão Logística e LinearSVC, ambos com representação TF-IDF. A comparação considera os resultados de cada modelo e a diferença entre estimar probabilidades e produzir escores de margem.

8.1 Fundamentação Teórica

8.1.1 Regressão Logística

A Regressão Logística é um modelo supervisionado que estima probabilidades de classe a partir de uma combinação linear dos atributos (Hastie et al., 2009). A função sigmoide é usada no caso binário e a softmax, no multinomial. Os coeficientes são estimados por máxima verossimilhança. Termos de regularização, como as penalidades L1 e L2, limitam a complexidade do ajuste em uma representação textual com muitos atributos.$L_1 L_2$

A Regressão Logística foi incluída porque aceita matrizes esparsas de TF-IDF e fornece probabilidades que podem ser avaliadas e calibradas. O parâmetro class_weight='balanced' ajusta os pesos das classes durante o treinamento. Sua utilidade neste projeto deve ser julgada pelas métricas obtidas, sobretudo pela capacidade de identificar avaliações negativas.

Neste projeto, a Regressão Logística é uma candidata para atingir F1-score de pelo menos 0,80 na classe negativa, composta pelas notas 1 e 2. Seus coeficientes podem ajudar a examinar quais termos têm maior influência na classificação. O modelo também produz probabilidades, mas o uso de um limiar operacional

depende de validação e calibração próprias, realizadas posteriormente na Etapa 3.≥ n

8.1.2 Linear Support Vector Classifier

O LinearSVC é um classificador supervisionado que busca uma fronteira linear com margem entre as classes no espaço de atributos do TF-IDF (Hastie et al., 2009). O treinamento usa uma perda de margem, controlada pelo parâmetro C. Para mais de duas classes, a implementação pode empregar a estratégia um contra todos. O modelo fornece escores de decisão, que não devem ser lidos diretamente como probabilidades calibradas.C

O LinearSVC foi incluído como alternativa à Regressão Logística para texto vetorizado por TF-IDF. Essa representação é esparsa e tem muitos atributos, condição compatível com classificadores lineares. A implementação baseada em LIBLINEAR foi usada por sua eficiência nesse tipo de dado. O desempenho do modelo neste projeto é apresentado na comparação empírica adiante.

O LinearSVC também foi avaliado frente à meta de F1-score de 0,80 para a classe negativa. O treinamento usa pesos balanceados para considerar a diferença de frequência entre as classes. Os coeficientes do classificador podem indicar termos associados às decisões, mas a interpretação de motivos de insatisfação requer análise adicional dos comentários.≥ C

8.2 Metodologia e Implementação dos Modelos

8.2.1 Aplicando a Regressão Logística

A Regressão Logística foi implementada em um Pipeline do scikit-learn. O TfidfVectorizer transforma os comentários em atributos de unigramas e bigramas, remove acentos, usa frequência sublinear e limita o vocabulário por frequência. O classificador é ajustado depois dessa transformação, dentro do mesmo pipeline.

O classificador LogisticRegression usa C=1,0, class_weight='balanced', semente 42 e limite de 2.000 iterações. Os pesos balanceados consideram a frequência das classes no treino. O teste foi mantido fora do ajuste do pipeline e usado para avaliação após o treinamento.L_2

Os bigramas permitem representar expressões de duas palavras, enquanto os limites de frequência retiram termos muito raros ou frequentes do vocabulário. A utilidade dessa configuração é avaliada pelos resultados de classificação apresentados nesta seção.

8.2.2 Aplicando o LinearSVC

O LinearSVC foi ajustado em um Pipeline com a mesma configuração de TF-IDF usada na comparação. O classificador empregou class_weight='balanced', semente fixa e o modo automático de resolução. Assim, a comparação concentra-se principalmente no estimador usado após a vetorização.

O parâmetro C do LinearSVC foi pesquisado com GridSearchCV em três partições de validação cruzada, usando F1 macro como critério. A grade [0,01; 0,1; 0,5; 1,0] produziu 12 ajustes. Depois da seleção no treino, o modelo escolhido foi avaliado no conjunto de teste.C

O F1 macro dá o mesmo peso às três classes e, por isso, foi usado na comparação preliminar do LinearSVC. Esse critério não equivale à Meta 1, que se refere especificamente ao F1 da classe negativa. Os dois resultados são apresentados separadamente na avaliação.$\geq C$

8.3 Resultados e Discussão

8.3.1 Desempenho da Regressão Logística

No teste, a Regressão Logística alcançou acurácia de 80,40%. O F1-score foi 0,81 para a classe negativa e 0,90 para a positiva. Na classe negativa, a precisão foi 0,79 e o recall, 0,83. Esses valores descrevem o desempenho observado neste conjunto de teste.F_1

A classe neutra teve resultado inferior: F1-score de 0,34 e recall de 0,44, com 279 acertos entre 633 avaliações neutras. O modelo identifica parte desses casos, mas confunde a classe intermediária com as demais. Esse é um limite relevante para a interpretação da acurácia global.F_1

A Regressão Logística atingiu a Meta 1 no teste histórico: o F1 da classe negativa foi 0,81, pouco acima do mínimo de 0,80. O recall de 0,83 indica que a maior parte das

avaliações negativas desse teste foi encontrada. O resultado não mede redução de retrabalho ou retenção de clientes, que dependeriam de uma avaliação operacional.

8.3.2 Desempenho do LinearSVC

No teste, o LinearSVC alcançou acurácia de 82,77%, F1-score de 0,82 na classe negativa e de 0,91 na positiva. O recall negativo foi 0,88 e a precisão, 0,77. Esses resultados permitem compará-lo à Regressão Logística, mas não demonstram por si só estabilidade em outras amostras.$C = 0{,}1 F_1 C = 0{,}1$

Na classe neutra, o LinearSVC obteve F1-score de 0,27, precisão de 0,29 e recall de 0,25. Sua acurácia global foi maior que a da Regressão Logística, 82,77% contra 80,40%, mas recuperou menos avaliações neutras. O resultado mostra que a escolha do modelo depende da métrica priorizada.F_1

O LinearSVC obteve F1-score de 0,82 na classe negativa, frente a 0,81 da Regressão Logística, e recall negativo de 0,88. Em compensação, seu F1 neutro foi 0,27, contra 0,34, e seu F1 macro foi 0,67, contra 0,68. Os dois modelos atingiram a Meta 1 no teste histórico. A Regressão Logística foi adotada como modelo oficial porque permite trabalhar com probabilidades, depois submetidas a calibração na Etapa 3; o LinearSVC permanece como referência de comparação.

9. Cálculo de Acurácia

Esta seção avalia o modelo de classificação de sentimentos adotado no projeto: TF-IDF seguido de Regressão Logística com pesos balanceados por classe. O desempenho foi medido nas 6.980 avaliações reservadas para teste, que não entraram no treinamento. Os cálculos e gráficos completos estão no Notebook 04 (notebooks/04_calculo_e_avaliacao_acuracia.ipynb); os números desta seção foram conferidos a partir de data/processed/modelo/metricas_modelo.json e da reexecução do modelo salvo.

9.1 Escolha das métricas

O roteiro da Etapa 2 separa métricas por tipo de problema: acurácia, precisão, recall, F1 e matriz de confusão para classificação; silhueta e índice Davies-Bouldin para agrupamento; MAE, RMSE e R² para regressão. O modelo deste projeto prevê uma entre três categorias (negativo, neutro ou positivo), o que o torna um classificador, apesar do nome Regressão Logística. Usar MAE, RMSE ou R² exigiria tratar essas categorias como números com distância definida entre si, o que não corresponde à pergunta que o projeto faz.

A Meta 1 fixa F1 mínimo de 0,80 para a classe negativa, e essa é a referência principal desta seção: o modelo existe para ajudar a localizar clientes insatisfeitos, e o F1 combina o recall,

que mostra quantas queixas reais foram encontradas, com a precisão, que mostra quantos alertas de insatisfação estavam certos.

9.2 Distribuição das classes e limites da acurácia

O conjunto de teste tem 4.298 avaliações positivas (61,58%), 2.049 negativas (29,36%) e 633 neutras (9,07%); o treino segue proporções semelhantes, com 17.190, 8.196 e 2.532 avaliações. Como a classe positiva domina, a acurácia isolada engana: um modelo que respondesse sempre "positivo" acertaria 61,58% dos casos sem identificar uma única queixa. Por isso o restante da seção examina cada classe separadamente, com atenção à negativa.

9.3 Matriz de confusão

A matriz de confusão cruza a classe real, definida pela nota do cliente, com a classe prevista pelo modelo a partir do texto. Na Tabela 2, cada linha corresponde a uma classe real e cada coluna a uma classe prevista; os acertos ficam na diagonal.

Tabela 2 – Matriz de confusão da Regressão Logística no conjunto de teste (linhas: classe real; colunas: classe prevista).

Classe real \ classe prevista	Negativo	Neutro	Positivo	Total real
Negativo	1.694	303	52	2.049
Neutro	237	279	117	633
Positivo	219	440	3.639	4.298
Total previsto	2.150	1.022	3.808	6.980

Fonte: elaborado pelo grupo a partir de data/processed/modelo/metricas_modelo.json e previsoes_teste.csv.

A diagonal soma 5.612 acertos (1.694 + 279 + 3.639) em 6.980 casos. O maior volume de erro passa pela classe neutra: 440 avaliações positivas e 303 negativas foram previstas como neutras, e 237 avaliações neutras foram previstas como negativas. A matriz mostra onde o modelo erra; entender por que exigiria ler os comentários envolvidos, o que fica como hipótese e não como conclusão. É possível que a nota 3 reúna elogio e crítica no mesmo texto, mas isso ainda precisa ser verificado nos exemplos classificados incorretamente.

9.4 Métricas de cada classe

Para medir uma classe isoladamente, ela é tratada como o resultado de interesse e as outras duas formam o grupo "resto", na abordagem chamada um contra todos. Nessa leitura, VP (verdadeiro positivo) é o caso da classe acertado; FP (falso positivo) é o caso de outra classe previsto como a classe analisada; FN (falso negativo) é o caso da classe previsto como outra; e VN (verdadeiro negativo) é todo o restante. Na matriz, VP é a diagonal da classe, FP é o total da coluna menos VP, FN é o total da linha menos VP, e VN é 6.980 menos VP, FP e FN.

Tabela 3 – Decomposição um contra todos da matriz de confusão e métricas por classe no conjunto de teste.

Classe analisada	VP	FP	FN	VN	Precisão	Recall	F1-score
Negativo	1.694	456	355	4.475	78,79%	82,67%	80,69%

Classe analisada	VP	FP	FN	VN	Precisão	Recall	F1-score
Neutro	279	743	354	5.604	27,30%	44,08%	33,72%
Positivo	3.639	169	659	2.513	95,56%	84,67%	89,79%

Fonte: elaborado pelo grupo a partir da matriz de confusão e do relatório de classificação do scikit-learn.

Para a classe negativa, por exemplo: FP = 237 + 219 = 456, FN = 303 + 52 = 355, e VN = 6.980 − 1.694 − 456 − 355 = 4.475. A tabela deixa o contraste claro: a classe positiva tem alta precisão, a negativa fica perto de 80% nas duas medidas, e a neutra tem o pior desempenho, com 743 falsos positivos para apenas 279 acertos.

9.5 Resultado frente à Meta 1

Acurácia = 5.612 / 6.980 = 0,8040 (80,40%)

Precisão negativa = 1.694 / (1.694 + 456) = 0,7879 (78,79%)

Recall negativo = 1.694 / (1.694 + 355) = 0,8267 (82,67%)

F1 negativo = (2 × 1.694) / (2 × 1.694 + 456 + 355) = 0,8069 (80,69%)

O F1 negativo, 0,8069, fica 0,69 ponto percentual acima do mínimo da Meta 1, que é 0,80: o critério é atingido no teste, com margem estreita.

As médias entre classes respondem outra pergunta e não substituem esse número. O F1 macro, que dá o mesmo peso às três classes, é 0,6806, puxado para baixo pela classe neutra; o F1 ponderado, que pesa cada classe pelo seu tamanho, é 0,8203, mais próximo do desempenho da classe positiva, que é a maior. A classe neutra tem o pior F1, 33,72%, o que pede investigação: talvez parte das avaliações de nota 3 tenha texto ambíguo demais para o modelo separar, mas isso só se confirma olhando os erros um a um.

9.6 Curvas ROC e precisão-recall

As métricas anteriores usam a classe final escolhida pelo modelo. As curvas ROC e precisão-recall avaliam a probabilidade estimada de "negativo" em todos os limiares possíveis, tratando a classe negativa como positiva e o restante como "não negativo".

A ROC AUC da classe negativa é 0,9484: ao comparar uma avaliação negativa e uma não negativa escolhidas ao acaso, há cerca de 94,84% de chance de a negativa receber a probabilidade maior. A precisão média, ou PR AUC, é 0,8690, bem acima da proporção de negativos no teste, que é 0,2936. Isso indica que a ordenação produzida pelo modelo carrega informação real sobre essa classe.

Essas métricas avaliam ordenação, não calibração: não dizem se uma probabilidade de 70% corresponde de fato a 70% de chance real, e essa calibração não foi verificada aqui. Qualquer uso operacional dessas probabilidades, inclusive para definir um limiar de atendimento, exige essa validação à parte.

9.7 Validação cruzada

O teste mostra o desempenho em uma única divisão dos dados. Para observar a variação entre divisões, o conjunto de treino, com 27.918 avaliações, foi avaliado por validação cruzada estratificada em cinco partições, sem envolver o teste em nenhum momento.

O F1 negativo médio nas cinco partições foi 80,33%, com desvio padrão de 0,60 ponto percentual (partições de 80,61%, 80,76%, 80,85%, 80,20% e 79,22%); a partição mais fraca ficou abaixo do limiar da Meta 1. Esse desvio padrão descreve a variação entre partições, não um intervalo de confiança.

A proximidade entre o resultado do teste e a média da validação cruzada indica que o desempenho não depende só daquela divisão específica. A partição mais fraca, por outro lado, mostra que o modelo opera perto do limite da meta, e que pequenas mudanças nos dados podem derrubar o F1 abaixo de 0,80.

9.8 Textos semelhantes entre treino e teste

A checagem de sobreposição não encontrou texto limpo idêntico entre treino e teste. Após o processamento pelo analisador TF-IDF, porém, 123 avaliações de teste, 1,76% do total, ficam com a mesma sequência de termos de alguma avaliação de treino. Frases curtas e comuns, como "ótimo tudo certo" e "otimo tudo certo", bastam para isso acontecer.

Excluindo essas 123 avaliações, a acurácia cai para 80,17% e o F1 negativo para 0,8061: uma mudança pequena, que não altera a conclusão sobre a Meta 1. A coincidência não prova que uma avaliação foi copiada da outra, já que são clientes diferentes, mas limita a leitura de independência total entre os conjuntos. A checagem de sobreposição do projeto deveria passar a comparar os textos já normalizados, do jeito que o vetorizador os processa.

9.9 Sensibilidade ao limiar

O Notebook 04 também testa o que acontece ao mudar o limiar de probabilidade que classifica uma avaliação como negativa:

Limiar para sinalizar negativo	Precisão negativa	Recall negativo
0,30	72,61%	90,58%
0,40	78,43%	86,04%

Fonte: elaborado pelo grupo a partir do Notebook 04.

Um limiar mais baixo encontra mais queixas reais, ao custo de mais alertas incorretos; um limiar mais alto faz o inverso. Esses valores foram calculados no próprio conjunto de teste e servem só para ilustrar essa troca. A escolha de um limiar operacional precisa ser feita em dados de validação e depois conferida em dados ainda não usados nessa escolha.

9.10 Síntese da avaliação

Tabela 4 – Principais resultados do modelo oficial.

Medida	Resultado
Acurácia no teste	80,40%
Precisão da classe negativa no teste	78,79%
Recall da classe negativa no teste	82,67%
F1 da classe negativa no teste	0,8069
F1 macro no teste	0,6806

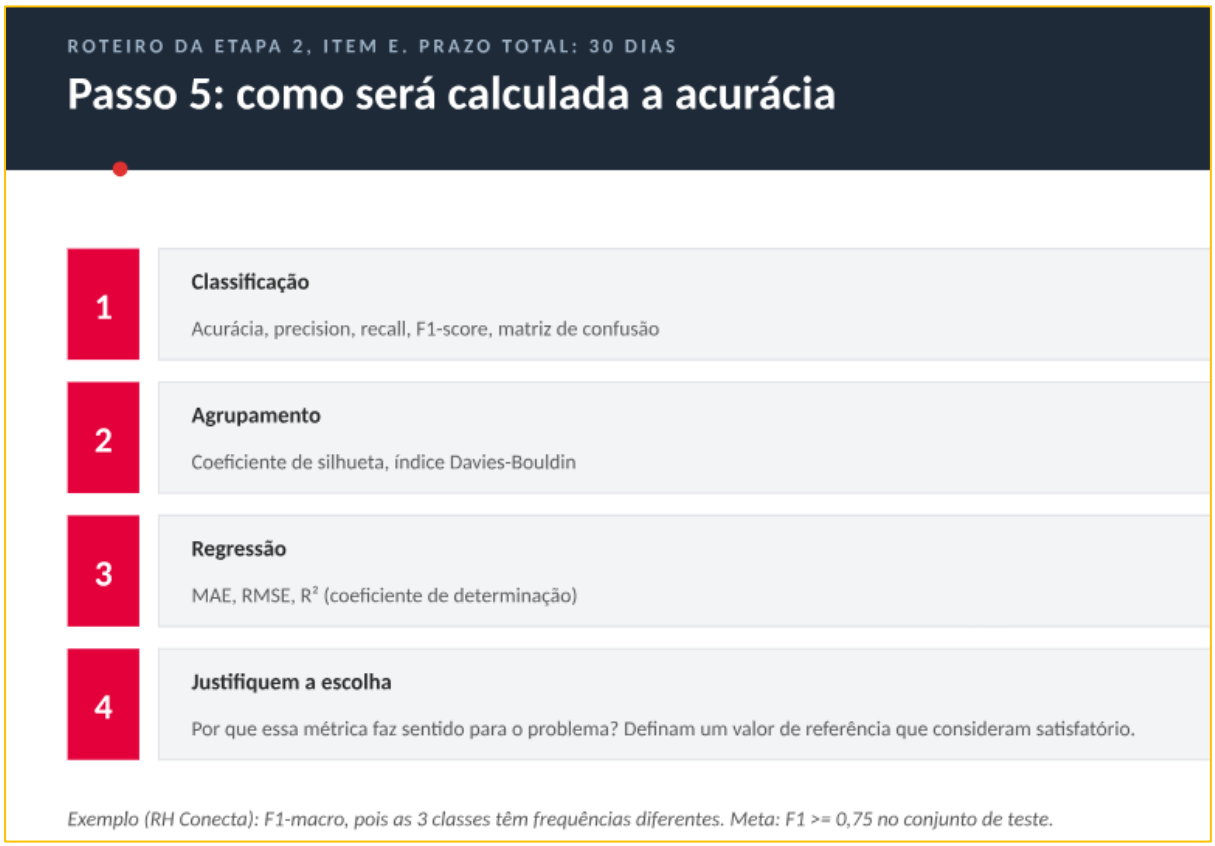
Medida	Resultado
F1 ponderado no teste	0,8203
ROC AUC da classe negativa no teste	0,9484
Precisão média (PR AUC) da classe negativa no teste	0,8690
F1 negativo na validação cruzada do treino	0,8033 ± 0,0060

Fonte: elaborado pelo grupo a partir do Notebook 04.

O modelo atinge a Meta 1 no teste, com F1 negativo pouco acima do mínimo exigido, e a validação cruzada confirma essa margem estreita: uma das cinco partições fica abaixo dela. A classe neutra segue como o ponto fraco, com desempenho bem inferior ao das outras duas.

Isso deixa três frentes claras para a Etapa 3: investigar os erros da classe neutra, avaliar o ajuste do parâmetro C da Regressão Logística, usado aqui no valor padrão, e validar qualquer proposta de uso operacional das probabilidades ou de mudança no limiar de classificação. A matriz e as métricas desta seção dão a evidência necessária para discutir a Meta 3, cujo cumprimento segue o critério já definido no projeto.

Slide de referência do professor: "Passo 5: como será calculada a acurácia" (roteiro da Etapa 2).



10. Avaliação Final

11. Cronograma de Atividades

O cronograma completo e editável pode ser consultado na planilha Cronograma - V270826.xlsx disponível no repositório público.

Tabela 5 – Cronograma do projeto

TAREFA	ATRIBUÍDO PARA	PROGRESSO	INÍCIO	TÉRMINO
Etapa 1		100%		
Definição do grupo de trabalho	Geral	100%	10/8/26	25/8/26
Buscar dataset	Igor	100%	24/8/26	25/8/26
Detalhamento da organização	Igor/Lucas	100%	25/8/26	27/8/26
Detalhamento da área de atuação	Igor/Kayo	100%	25/8/26	27/8/26
Apresentação (metadados)	Igor/Jaqueline	100%	25/8/26	27/8/26
Criar cronograma do projeto	Jaqueline	100%	25/8/26	26/8/26
Criar diretório no GitHub	Lucas	100%	25/8/26	26/8/26
Entregável Etapa 1	Kayo	100%	28/8/26	28/8/26
Etapa 2				
Definição das bibliotecas	Igor	50%	29/8/26	2/9/26
Análise exploratória da base	Igor	50%	1/9/26	7/9/26
Tratamento da base de dados (preparação)	Lucas	50%	7/9/26	18/9/26
Tratamento da base de dados (treinamento)	Lucas	50%	7/9/26	18/9/26
Detalhamento das bases teóricas dos métodos	Jaqueline	50%	19/9/26	24/9/26
Detalhamento do cálculo de acurácia	Kayo	20%	19/9/26	24/9/26
Entregável Etapa 2	Jaqueline	0%	25/9/26	25/9/26
Etapa 3				

Identificar 5 temas recorrentes de insatisfação	Lucas Mendes	100%	26/9/26	14/10/26
Otimizar parâmetro C da regressão logística	Lucas Mendes	100%	26/9/26	14/10/26
Validação operacional, calibração e limiares	Igor Couto	100%	10/10/26	17/10/26
Descrição dos resultados preliminares	Jaqueline	100%	11/10/26	19/10/26
Esboço do storytelling	Kayo Nukui	100%	17/10/26	22/10/26
Revisão e entrega do PDF Etapa 3	Kayo Nukui	0%	23/10/26	23/10/26
Etapa 4	-			
Revisão final do relatório técnico (todas as fases)	-	0%	24/10/26	7/11/26
Apresentação do storytelling (PPT ou similar)	-	0%	2/11/26	14/11/26
Produção e publicação do vídeo no YouTube	-	0%	11/11/26	19/11/26
Consolidação dos arquivos no GitHub	-	0%	18/11/26	19/11/26
Entregável Etapa 4	-	0%	20/11/26	20/11/26

12. Repositório no GitHub

Abaixo está a estrutura do repositório com a descrição de cada pasta e arquivo relevante.

Repositório público do projeto: https://github.com/lucasmendes94/Drop-Table-Projeto-Aplicado-II

Tabela 6 – Estrutura dos arquivos no repositório

Pasta / arquivo	Descrição
README.md	Apresentação do projeto, acesso rápido aos documentos, equipe, estrutura e andamento.
[PA2] Etapa 1 - Drop Table - V280826.docx	Relatório técnico da Etapa 1 revisado após os comentários do professor.
Cronograma - V270826.xlsx	Cronograma completo, editável e legível das quatro etapas.
VALIDACAO_COMENTARIOS.md	Matriz de atendimento dos comentários e evidências de cada correção.
docs/rascunhos/	Versões anteriores preservadas para histórico.
data/raw/	Dados originais mantidos localmente e fora do versionamento.

data/processed/	Dados tratados e derivados mantidos localmente.
notebooks/	Aquisição, EDA, preparação textual, modelagem e avaliação.
src/	Funções e pipeline reutilizável do projeto.
reports/figures/	Gráficos e imagens usados nos relatórios e na apresentação.
requirements.txt	Dependências previstas para análise e modelagem em Python.

PARTE III — ETAPA 3: APLICAÇÃO DO MÉTODO ANALÍTICO, AVALIAÇÃO DE DESEMPENHO, PROPOSTA DE PRODUTO E STORYTELLING

Esta parte apresenta o trabalho da Etapa 3 e se apoia na preparação dos dados e na comparação de modelos das seções anteriores. Na Etapa 2, o LinearSVC obteve F1 de 0,82 para a classe negativa no teste exploratório. A Regressão Logística, escolhida para as análises seguintes por fornecer probabilidades passíveis de calibração, obteve F1 negativo de 0,8069 no teste histórico de 6.980 avaliações. Aqui são examinados o ajuste de C, os temas das queixas, a avaliação por pedido e uma proposta de uso dos resultados.

13. Aplicação do Método Analítico e Otimização de Hiperparâmetros

13.1 Otimização do Parâmetro de Regularização C

O pipeline oficial combina TF-IDF, com unigramas e bigramas, min_df=2, max_df=0,95, sublinear_tf=True e remoção de acentos por Unicode NFKD, à Regressão Logística balanceada. O treinamento usa max_iter=2000 e semente 42. A busca de C foi feita em cinco partições do conjunto de treino, com 27.918 avaliações. O conjunto de teste não participou da seleção.

A escolha de C priorizou o F1 médio da classe negativa na validação cruzada. Foram testados nove valores entre 0,01 e 100,0, totalizando 45 ajustes. Esse critério corresponde à Meta 1, que trata da identificação de avaliações negativas.

Tabela 7 — Otimização de C em validação cruzada estratificada de 5 partições no treino

Parâmetro C	F1 Negativo Médio (5 folds)	Desvio Padrão Amostral	F1 Macro Médio
0,10	0,7894	0,0089	0,6697
0,30	0,8016	0,0086	0,6774
1,00 (Baseline Selecionado)	0,8034	0,0066	0,6771
3,00	0,8018	0,0069	0,6697
10,00	0,7958	0,0095	0,6563

Fonte: Elaboração própria com base em reports/etapa3/comparacao_c.csv.

Com C=1,0, o F1 negativo médio foi 0,8034 nos cinco folds, com desvio padrão de 0,0066. A análise preliminar do Notebook 03 havia indicado C=0,5 ao usar F1 macro em três folds, com 0,6775 frente a 0,6750. As escolhas respondem a critérios diferentes; para a Meta 1, o grupo manteve C=1,0.

13.2 Decomposição Temática e Regras Léxicas de Insatisfação

A NMF com cinco componentes foi aplicada às 8.196 avaliações negativas do treino, representadas por TF-IDF. Quatro componentes continham termos ligados a atraso ou não recebimento, como 'não recebi', 'não chegou' e 'prazo de entrega'. Os componentes mostram concentração de vocabulário logístico, mas não equivalem a cinco categorias operacionais distintas. Esta análise está registrada em reports/etapa3/topicos_nmf.json. O Notebook 05 é um experimento exploratório distinto, feito com 10.245 avaliações negativas de treino e teste e outro pré-processamento; seus resultados não entram nas tabelas desta parte. Os cinco temas quantificados a seguir vêm de regras léxicas, não dos componentes da NMF.

Para examinar motivos mais específicos, o grupo aplicou regras de palavras-chave multirrótulo às 8.196 avaliações negativas do treino. As expressões regulares estão em src/temas_insatisfacao.py. Uma avaliação pode ativar mais de uma regra; as contagens da tabela, portanto, não são mutuamente exclusivas.

Tabela 8 — Temas de insatisfação identificados por regras léxicas no conjunto de treino

Tema de Insatisfação	Menções Detectadas	% das 8.196 Negativas	Padrão Léxico Representativo
Atraso ou não recebimento	2.700	32,94%	atras*, demor*, nao recebi, nao entreg*
Atendimento, troca ou reembolso	926	11,30%	atendimento, sem resposta, reembols*, troca*
Defeito, avaria ou baixa qualidade	625	7,63%	defeit*, quebrad*, avariad*, pessima qualidade
Produto diferente do solicitado	592	7,22%	errad*, diferente do, veio outro, nao condiz
Pedido incompleto ou peças faltantes	520	6,34%	faltando, incomplet*, so veio um, falta de pecas

Fonte: Elaboração própria com base em reports/etapa3/cinco_temas.json.

Pelo menos uma regra foi ativada em 4.661 avaliações, ou 56,87% das negativas do treino. Houve 649 avaliações com mais de um tema e 3.535 sem correspondência com os padrões definidos. Essas frequências são exploratórias: não houve anotação humana independente para medir a precisão ou o recall de cada tema, e os percentuais não representam taxas auditadas de falhas operacionais.

14. Medidas de Acurácia, Validação por Pedido e Limiares Operacionais

14.1 Desempenho no Teste Histórico

No teste histórico de 6.980 avaliações, a Regressão Logística com C=1,0 alcançou acurácia de 80,40%. Para a classe negativa, a precisão foi 78,79%, o recall, 82,67%, e o F1-score, 0,8069. Assim, a Meta 1 de F1 pelo menos 0,80 foi atingida nesse teste, com margem de 0,69 ponto percentual. O suporte foi de 2.049 avaliações negativas, 4.298 positivas e 633 neutras. O F1 da classe positiva foi 0,8979 e o da neutra, 0,3372.

14.2 Auditoria de Particionamento e Validação Complementar Agrupada por Pedido

A divisão histórica tinha 19 pedidos presentes no treino e no teste. A auditoria também encontrou 56 avaliações de teste cujo texto limpo, após a remoção de acentos feita em src/etapa3_validacao.py, coincidia com algum texto de treino. Esse critério difere daquele da Seção 9.8, que encontrou 123 coincidências ao comparar a sequência de termos produzida pelo analisador TF-IDF. Para avaliar a separação por pedido, o grupo fez uma nova divisão com StratifiedGroupKFold, destinando aproximadamente 60% ao ajuste, 20% à validação e 20% ao teste, e aplicou bootstrap por pedido com 1.000 reamostragens.

- **Desempenho Pontual no Teste Agrupado:** F1-score da classe negativa de 0,7970, com Precisão de 0,7776 e Recall de 0,8175 (6.980 avaliações avaliadas no teste agrupado).
- **Intervalo de Confiança Bootstrap (95%):** F1 negativo estimado entre 0,7829 e 0,8106. Em 66,8% das 1.000 reamostragens, o F1 negativo ficou abaixo de 0,80.

O F1 negativo passou de 0,8069 no teste histórico para 0,7970 no teste da nova divisão agrupada. Como a amostra e o treinamento mudaram, a diferença não pode ser atribuída apenas aos 19 pedidos compartilhados. Os dois valores devem ser lidos com seus respectivos desenhos de avaliação.

14.3 Calibração de Probabilidades e Simulação de Limiares

Os pesos balanceados alteram a relação entre as probabilidades brutas do modelo e a frequência das classes. Por isso, o grupo ajustou um calibrador sigmoide na partição de validação. No teste agrupado, o escore de Brier passou de 0,0835 para 0,0817 e o erro de calibração esperado (ECE), de 0,0364 para 0,0151. Esses resultados descrevem a calibração nessa amostra; não demonstram desempenho em produção.

A partir das probabilidades calibradas, simularam-se três estratégias de limiares operacionais sobre o conjunto de teste agrupado:

Tabela 9 — Simulação de limiares operacionais na probabilidade calibrada no teste agrupado

Critério de Validação	Limiar	Precisão no Teste	Recall no Teste	Alertas / 1.000	Falsos Alertas / 1.000
F1 Máximo	0,32	0,7388	0,8946	355,4	92,8
Recall Mínimo >= 0,85 (Recomendado)	0,40	0,7709	0,8604	327,7	75,1
Precisão Mínima >= 0,80	0,45	0,7860	0,8336	311,3	66,6

Fonte: Elaboração própria com base em docs/ETAPA3_validação.docx.

O limiar de 0,45 cumpriu o critério de precisão mínima de 0,80 na validação, mas obteve 0,7860 no teste agrupado. Após revisar os três cenários, o grupo recomenda o corte de 0,40 para estudo de uma triagem assistida, por priorizar a recuperação de avaliações negativas. O documento de validação usa o F1 máximo como referência padrão; a recomendação do grupo é preliminar, pois os custos de queixas perdidas e alertas falsos ainda não foram medidos e nenhum limiar foi implantado em produção. Na simulação do teste agrupado, esse corte obteve recall de 86,04% e precisão de 0,7709, com 327,7 alertas e 75,1 falsos alertas por 1.000 avaliações.

15. Resultados Preliminares, Proposta de Produto e Modelo de Negócios

15.1 Caracterização da Solução Proposta

O produto proposto é uma solução de triagem de avaliações de pós-venda com dois módulos previstos: um Painel Operacional de CX e uma API de Triagem Contínua. A proposta utiliza os modelos e as análises desta etapa. O Painel e a API ainda não foram implementados nem operam na ConectaShop.

Na arquitetura proposta, a triagem ocorreria após o cliente publicar uma avaliação. A Regressão Logística calcularia a probabilidade calibrada de classificação negativa. O Painel permitiria consultar as avaliações por período e pelos cinco temas explorados no treino: atraso ou não recebimento (32,94%), atendimento ou troca (11,30%), defeito ou qualidade (7,63%), produto divergente (7,22%) e pedido incompleto (6,34%). A fila priorizada é uma funcionalidade proposta e ainda não teve seu efeito no atendimento medido.

15.2 Beneficiários Operacionais Propostos

• Atendimento e SAC: a proposta prevê uma fila de avaliações priorizadas pelo escore calibrado, para que os analistas decidam quais casos examinar primeiro. O tempo de resposta ainda não foi medido.

• Logística: os indicadores agregados de atraso ou não recebimento podem orientar uma investigação sobre prazos e entregas. A análise atual não atribui essas menções a transportadoras específicas.

• Gestão de vendedores parceiros: em uma etapa futura, os temas de defeito ou qualidade (7,63%) e produto divergente (7,22%) poderão ser relacionados a seller_id. O estudo atual não mediu reincidência por vendedor.

15.3 Modelo de Negócios e Estrutura de Precificação Proposta

O modelo de negócios proposto é SaaS B2B, com planos definidos pelo volume mensal de avaliações processadas. Os valores abaixo são uma proposta de precificação, não resultado de teste de mercado.

• **Plano Starter (R$ 1.500/mês):** Destinado a operações com até 10.000 avaliações mensais, incluindo visualização no painel gerencial e consolidações periódicas.

• **Plano Growth (R$ 4.500/mês):** Destinado a operações com até 50.000 avaliações mensais, incluindo integração por API e parametrização dinâmica de limiares operacionais.

• **Plano Enterprise (a partir de R$ 10.000/mês):** Volumetrias superiores customizadas, suporte a múltiplos catálogos e acordos de nível de serviço (SLA).

A simulação do limiar de 0,40 estimou 327,7 alertas, dos quais 75,1 falsos, a cada 1.000 avaliações. Esses números ajudam a dimensionar uma possível fila de revisão. O estudo não mediu retorno financeiro, redução de cancelamentos ou economia de horas de atendimento.

16. Esboço de Storytelling em Quatro Atos

Ato 1: O Ponto Cego da Triagem Manual na ConectaShop

No cenário fictício da ConectaShop, as notas de 1 a 5 indicam satisfação ou insatisfação, mas não explicam o motivo descrito pelo cliente. A leitura dos comentários pode revelar, por exemplo, atraso ou avaria. Sem uma triagem de texto, essas queixas permanecem misturadas às demais avaliações.

Ato 2: O Método de Classificação Textual Ponderada

O grupo treinou um classificador com TF-IDF, incluindo unigramas e bigramas, e Regressão Logística com pesos balanceados. A validação cruzada no treino selecionou C=1,0 com foco no F1 da classe negativa. Esse modelo fornece a base analítica para a triagem proposta.

Ato 3: A Estrutura Empírica da Insatisfação

No teste histórico, o modelo obteve F1 negativo de 0,8069, recall de 82,67% e acurácia de 80,40%. A NMF mostrou concentração de termos sobre problemas de entrega. Depois, regras de palavras-chave aplicadas às avaliações negativas do treino identificaram menções a atraso ou não recebimento (32,94%), atendimento ou troca (11,30%), defeito ou qualidade (7,63%), produto diferente (7,22%) e pedido incompleto (6,34%). As regras são exploratórias.

Ato 4: Ação Operacional com Limiares Calibrados

A solução foi concebida para triar avaliações já publicadas. No teste agrupado, a calibração sigmoide reduziu o escore de Brier para 0,0817. A simulação com limiar de 0,40 obteve recall de 86,04% e estimou 327,7 alertas, dos quais 75,1 seriam falsos, a cada 1.000 avaliações. Esses resultados ajudam a planejar uma futura fila de atendimento; os efeitos sobre clientes e parceiros ainda não foram medidos.

17. Síntese de Rastreabilidade e Limitações Metodológicas

Tabela 10 — Síntese de rastreabilidade das afirmações numéricas da Etapa 3

Dado Numérico Utilizado	Significado Analítico	População e Denominador	Arquivo de Origem
27.918 / 6.980	Divisão Treino / Teste	34.898 avaliações tratadas (80/20)	reports/etapa3/execucao.json
80,40% / 0,8069	Acurácia / F1 Negativo Teste	6.980 avaliações do teste histórico	reports/etapa3/comparacao_teste.json
82,67% / 78,79%	Recall / Precisão Negativa	2.049 avaliações negativas de teste	reports/etapa3/comparacao_teste.json
0,7970	F1 Negativo Teste Agrupado	6.980 avaliações agrupadas por pedido	docs/ETAPA3_validação.docx
32,94% (2.700)	Tema Atraso / Não Entrega	8.196 avaliações negativas de treino	reports/etapa3/cinco_temas.json
11,30% (926)	Tema Atendimento / Troca	8.196 avaliações negativas de treino	reports/etapa3/cinco_temas.json
327,7 e 75,1	Alertas Totais e Falsos / 1.000	Simulação no limiar 0,40 (teste)	docs/ETAPA3_validação.docx

Fonte: Elaboração própria com base nos relatórios técnicos e notebooks da Etapa 3.

17.1 Limitações Técnicas Reconhecidas

• Rótulos baseados nas notas: as classes foram definidas pela nota do cliente, com 1 e 2 como negativo, 3 como neutro e 4 e 5 como positivo. Os comentários não foram rotulados independentemente por avaliadores humanos.

• Classe neutra: o F1-score foi 33,72% no teste histórico. O resultado limita o uso do classificador quando é importante distinguir avaliações intermediárias.

• Temas exploratórios: as frequências dos cinco temas vêm de expressões regulares aplicadas ao treino. Não foram medidas precisão e recall para cada tema.

18. Referências

BLEI, D. M.; NG, A. Y.; JORDAN, M. I. Latent Dirichlet Allocation. Journal of Machine Learning Research, v. 3, p. 993-1022, 2003. Disponível em: https://jmlr.org/papers/v3/blei03a.html. Acesso em: 27 ago. 2026.

BRIER, Glenn W. Verification of forecasts expressed in terms of probability. Monthly Weather Review, v. 78, n. 1, p. 1-3, 1950.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning**: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009. Disponível em: https://www.sas.upenn.edu/~fdiebold/NoHesitations/BookAdvanced.pdf. Acesso em: 19 set. 2026.

JURAFSKY, D.; MARTIN, J. H. Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models. 3. ed. Manuscrito online, 2026. Disponível em: https://web.stanford.edu/~jurafsky/slp3/index.html. Acesso em: 27 ago. 2026.

LEE, Daniel D.; SEUNG, H. Sebastian. Learning the parts of objects by non-negative matrix factorization. Nature, v. 401, n. 6755, p. 788-791, 1999.

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle. Disponível em: https://www.kaggle.com/olistbr/brazilian-ecommerce/home. Acesso em: 27 ago. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, n. 85, p. 2825-2830, 2011. Disponível em: https://www.jmlr.org/papers/v12/pedregosa11a.html. Acesso em: 27 ago. 2026.

PLATT, John C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. Advances in Large Margin Classifiers, v. 10, n. 3, p. 61-74, 1999.

ZADROZNY, Bianca; ELKAN, Charles. Transforming classifier scores into accurate multiclass probability estimates. In: Proceedings of the eighth ACM SIGKDD international conference on Knowledge discovery and data mining, p. 694-699, 2002.